

Statystyczna Analiza Danych

zajęcia laboratoryjne 6

Wybrane funkcje matematyczne i statystyczne

Bioinformatyka II rok

1 Wprowadzenie - pliki do pobrania

R umożliwia używanie wielu wyspecjalizowanych, mniej lub bardziej popularnych funkcji matematycznych i statystycznych. Protokół obejmuje wprowadzenie w zagadnienia analizy statystycznej i przedstawienie wybranych metod. Dane wykorzystywane do poniższych przykładów:

- przykladoweDaneZBrakami.csv
- przykladoweDaneBezBrakow.csv
- przykladowe2Grupy.csv

Wymagane pakiety: *Hmisc*, *dplyr*, *ggpubr*, *car*, *dunn.test*, *FSA*.

2 Wprowadzenie do podstawowych zagadnień statystycznej analizy danych

Wprowadzenie w statystyczną analizę danych należy rozpocząć od przedstawienia etapów projektowania badania statystycznego:

- zdefiniowanie problemu badawczego, określenie celu, postawienie hipotezy badawczej,
- zebranie danych: określenie badanych parametrów, określenie skali pomiarowej, zebranie odpowiednio dużej próby,
- weryfikacja danych,
- analiza statystyczna z zastosowaniem odpowiednio dobranych testów, wizualizacja danych,
- interpretacja wyników.

Często popełniany błąd to zbyt mała liczność badanej próby. W praktyce jednak, badana próba ma często ograniczoną liczbę przypadków (wynika to z ograniczeń finansowych). Należy mieć na uwadze, że im większa liczba przypadków tym mniejszy błąd. Próby o małej liczności charakteryzuje niska moc testu, co oznacza, że mogą być one niewystarczające do wykrycia istotnych efektów.

3 Charakterystyka zmiennych (rodzaje zmiennych i skale pomiarowe)

Dane mogą mieć charakter ilościowy i jakościowy:

- dane ilościowe – mierzalne, wyrażone za pomocą wartości liczbowych (za pomocą jednostek miary w pewnej skali):
 - ciągle – przyjmują wartości z dowolną dokładnością z określonego przedziału liczbowego (np. stężenie pewnego parametru we krwi, kg, cm),
 - dyskretne – przyjmują określone wartości z pewnego przedziału (np. skala ocen na studiach, liczby dni choroby w roku).
- dane jakościowe – niemierzalne, wyrażone w pewnych kategoriach (np. kody, symbole, nazwy).

Skale pomiarowe:

- skala nominalna – nie można uporządkować (np. płeć, grupa krwi).
- skala porządkowa – można ustalić naturalny porządek (np. wykształcenie, stadium choroby).
- skala interwałowa (przedziałowa) – można ustalić naturalny porządek i można oszacować różnice wielkości pomiędzy przedziałami. Skala interwałowa jest określona przez wskazanie stałej jednostki miary i relacji przy-
porządkowującej liczbę każdemu wynikowi obserwacji (np. temperatura w stopniach Celsjusza).
- skala ilorazowa – posiada wszystkie własności skali przedziałowej, ale charakteryzuje się stałymi stosunkami i zerem bezwzględny (np. masa, stężenie).

Określenie rodzaju danych i skali pomiarowych ogrywa kluczową rolę, ponieważ w zależności od charakteru zmiennych stosuje się różne testy statystyczne. Należy jednak zwrócić uwagę na fakt, że większość procedur statystycznych nie wymaga rozróżnienia pomiędzy skalą przedziałową i ilorazową.

4 Ocena danych wejściowych

Często otrzymane dane wejściowe, bez wcześniejszego przetwarzania nie nadają się do bezpośredniego użycia i przeprowadzenia analiz statystycznych. W danych mogą pojawiać się braki, wynikające z błędu popełnionego przez człowieka (zwłaszcza, jeśli dane gromadzone są przez większą grupę osób). Brakujące dane oznaczane są w R jako NA (*ang. Not Available*), funkcja pozwalająca na wyszukanie takich danych *is.na()*.

Przykład – *is.na()*

```
1 dane <- read.csv2("przykladoweDaneZBrakami.csv", sep = ";")
2
3 wektorZBrakamiDanych <- dane$HGB
4 is.na(wektorZBrakamiDanych) #zwraca wektor wartosci TRUE i FALSE
5 sum(is.na(wektorZBrakamiDanych)) #okresla ile jest wartosci NA w wektorze
6 which(is.na(wektorZBrakamiDanych)) #zwraca numery indeksow dla wartosci NA
```

R umożliwia zastosowanie różnych wariantów radzenia sobie z brakiem danych. Jednym z nich jest usunięcie brakujących danych. W przypadku usuwania takich danych z wektora należy funkcji *na.omit()*. Chcąc usunąć brakujące dane z ramki danych, należy użyć funkcji *complete.cases()*. Jednak poza usuwaniem danych zdecydowanie lepszym sposobem radzenia sobie z brakującymi danymi jest wstawienie sztucznych pomiarów.

Przykład – *na.omit()* - dla wektorów

```
1 wektorBezBrakowDanych <- na.omit(wektorZBrakamiDanych)
2 length(wektorZBrakamiDanych) #dlugosc wektora zawierajacego braki danych
3 length(wektorBezBrakowDanych) #dlugosc wektora po pominięciu brakow danych
```

Zauważ, że po wyświetleniu danych dla wektora “wektorBezBrakowDanych” uzyskujemy informacje, że pominięto konkretne dane (wskazane są także numery indeksów w wektorze).

Przykład – *complete.cases()* - dla ramek danych

```
1 complete.cases(dane) #zwraca FLASE dla wierszy zawierających NA
2 noweDane <- dane[complete.cases(dane), ]
```

Powyżej, poza znalezieniem wierszy zawierających niekompletne dane, przedstawiono sposób zapisania nowych danych z pominięciem wierszy z brakami.

Usuwanie brakujących danych to najprostsze rozwiązanie, jednak nie jest najlepsze, ponieważ redukcja danych prowadzi do pogorszenia właściwości procedur statystycznych. Zdecydowanie lepszym rozwiązaniem od usuwania jest wstawienie sztucznych pomiarów. Najczęściej wstawia się średnią lub medianę. Jeszcze innym, lepszym rozwiązaniem, jest dopasowanie modelu regresji na zbiorze kompletnych danych. Wstawiając w miejsca brakujące wartości wyznaczone z modelu regresji. Do wstawienia wartości należy wykorzystać funkcję *impute()*, która wymaga zainstalowania pakietu *Hmisc*.

Przykład – *impute()*

```
1 wektorZBrakamiDanych <- dane$HGB
2 impute(wektorZBrakamiDanych, 10) # imputuj wartosc 10 w miejsca NA
3 impute(wektorZBrakamiDanych, mean) # imputuj srednia
4 mean(wektorZBrakamiDanych, na.rm = TRUE) #oblicz srednia z pominiem NA
```

5 Statystyki opisowe

Statystyki opisowe wykorzystuje się do przedstawienia charakterystyki badanych grup poprzez ocenę parametrów. W przypadku zmiennych o charakterze mierzalnym statystyki opisowe pozwalają na określenie jak często badana cecha występuje, jaki jest rozkład badanej cechy lub jaka wartość jest najbardziej reprezentatywna. Podczas gdy, w przypadku zmiennych o charakterze niemierzalnym można określić licznosc danego parametru.

Przykład – podstawowe statystyki opisowe

```
1 dane <- read.csv2("przykladoweDaneBezBrakow.csv", sep = ";")
2 attach(dane)
3
4 range(wiek)
5 mean(wiek)
6 median(wiek)
7 IQR(wiek)
8 var(wiek)
9 sd(wiek)
```

Poniżej opisano działanie funkcji stosowanych do statystyk opisowych, a w nawiasach podano potrzebne do zainstalowania pakiety:

- `max(base)` - wartość maksymalna w próbie.
- `min(base)` - wartość minimalna w próbie.
- `length(base)` - liczba elementów w próbie.
- `range(base)` - przedział zmienności próby.
- `mean(stats)` - średnia arytmetyczna, na jej wartość mają wpływ skrajne wartości.

- `weighted.mean(stats)` - średnia ważona, drugim argumentem tej funkcji jest wektor wag.
- `median(stats)` - mediana (wartość środkowa), na jej wartość nie mają wpływu wartości skrajne.
- `IQR(stats)` - rozstęp międzykwartylowy, czyli różnica między górnym, a dolnym kwartylem.
- `var(stats)` - wariancja w próbie.
- `sd(stats)` - odchylenie standardowe określa ona o ile wszystkie wartości badanego parametru różnią się od średniej arytmetycznej (może być zastosowana do eliminacji grubych błędów).
- `kurtosis(e1071)` - kurtoza miara koncentracji (spłaszczenia), dla rozkładu normalnego kurtoza równa jest 0, dla rozkładu wysmukłego kurtoza przyjmuje wartości większe od 0, dla rozkładu spłaszczonego kurtoza przyjmuje wartości mniejsze od 0.
- `skewness(e1071)` - skośność miara symetryczności, charakteryzuje odchylenie rozkładu od symetrii, możemy mieć do czynienia z rozkładem normalnym, lewoskośnym i prawoskośnym.
- `quantile(stats)` - kwantyl wybranego rzędu, drugim argumentem funkcji `quantile()` jest wektor kwantyli do wyznaczenia.
- `cor(stats)`, `cov(stats)` - macierz korelacji i kowariancji, argumentami może być para wektorów lub macierz (dla macierzy korelacje i kowariancje wyznaczone będą dla wszystkich par kolumn).

Wartości uzyskane w wyniku przeprowadzenia statystyk opisowych są podstawą dla dalszej analizy i wnioskowania statystycznego. Poniżej opisano inne przydatne funkcje R, np. `summary()`, która umożliwia podsumowanie wektora obserwacji. Wynik działania tej funkcji będzie inny w zależności od charakteru danych (ilościowych lub jakościowych).

Przykład – `summary()` dla danych ilościowych i jakościowych

```
1 summary(wiek)
2 summary(plec)
```

Obok funkcji `summary()` ważna jest też funkcja `table()`, która została wspomniana we wcześniejszych protokołach. Funkcja `table()` wyznacza tablice kontyngencji jednej lub większej liczby zmiennych wyliczeniowych.

Przykład – `table()`

```
1 table(plec)
2 table(grupa, plec)
```

Kolejną funkcją służącą do podsumowania jest `summarise()`, funkcję tą wykorzystuje się w przypadku podsumowania względem grup (w przypadku korzystania z funkcji `group_by()`). Do zastosowania powyższych funkcji konieczna jest instalacja pakietu `dplyr`. W poniższym przykładzie wykonano kilka podstawowych statystyk opisowych (`count`, `mean`, `sd`, `median`), które zostały obliczone dla całej próby z zastosowaniem grupowania:

Przykład – `group_by()`, `summarise()`

```
1 podsumowanie_wiek <- group_by(dane, grupa) %>%
2   summarise(
3     count = n(),
4     mean = format(round(mean(wiek, na.rm = TRUE), 2), nsmall = 2),
5     sd = format(round(sd(wiek, na.rm = TRUE), 2), nsmall = 2),
6     median = format(round(median(wiek, na.rm = TRUE), 2), nsmall = 2)
7   )
8 print(podsumowanie_wiek)
```

Chcąc zmienić kolejność wyświetlanych grup, należy wspomnieć o poziomach *levels()* i funkcji *ordered()*. Poziomy pokazują wszystkie możliwe warianty z danej kolumny (bez powtórzeń), podczas gdy funkcja *ordered()* pozwala zmienić ich kolejność. Funkcje te są istotne na przykład jeśli chcemy zmienić kolejność wyświetlanych grup na wykresach lub kolejność wyświetlania wyników w tabelach lub podsumowaniach.

Przykład – *levels()* i *ordered()*

```
1 dane$grupa
2 #zmiana kolejności w poziomie danych
3 dane$grupa <- ordered(dane$grupa, levels = c("KONTROLA", "CHOR1", "CHOR2"))
4 levels(dane$grupa)
```

6 Ocena zgodności danych z rozkładem normalnym

Dla każdego analizowanego parametru określa się jego zgodność z rozkładem normalnym. Rozkład normalny charakteryzuje się dzwonowatym kształtem krzywej symetrycznej względem wartości średniej. Spełnienie założenia o normalności z rozkładem normalnym jest często wymogiem do zastosowania odpowiednich testów statystycznych. Najczęściej stosowane testy do oceny zgodności z rozkładem normalnym: test Kołmogorowa-Smirnowa (*ks.test()*) i test Shapiro-Wilka (*shapiro.test()*).

Przykład – *shapiro.test()* dla parametru hsCRP z przykładowych danych

```
1 KONTROLA <- with(dane, dane[grupa == "KONTROLA", ])
2 CHOR1 <- with(dane, dane[grupa == "CHOR1", ])
3 CHOR2 <- with(dane, dane[grupa == "CHOR2", ])
4
5 shapiro.test(CHOR1$hsCRP)
6 shapiro.test(CHOR2$hsCRP)
7 shapiro.test(KONTROLA$hsCRP)
```

Przykład – *shapiro.test()* z wykorzystaniem grupowania dla parametru hsCRP

```
1 pvalueShapiroTestHSCRIP <- group_by(dane, grupa) %>%
2   summarise(
3     statistic = shapiro.test(hsCRP)$statistic,
4     p.value = shapiro.test(hsCRP)$p.value
5   )
6 pvalueShapiroTestHSCRIP
```

Przykład – Wydobywanie konkretnych wartości poprzez ustawione zmienne

```
1 #wydobywanie p-value dla wszystkich grup
2 pvalueShapiroTestHSCRIP$p.value
3
4 #wydobywanie p-value dla konkretnej grupy
5 pvalueShapiroTestHSCRIP$p.value[(pvalueShapiroTestHSCRIP$grupa == "CHOR1")]
```

Jeśli wartość *p-value* > 0.05 oznacza to, że rozkład danych nie różni się znacząco od rozkładu normalnego (możemy założyć normalność danych).

Graficzna ocena zgodności z rozkładem normalnym (do utworzenia wykresów wymagany jest pakiet *ggpubr*). Wykres pozwalający na sprawdzenie zgodności z rozkładem normalnym to wykres gęstości. Wykres ten zapewnia wizualną ocenę tego, czy rozkład ma kształt dzwonu. Funkcja *facet_wrap()* umożliwi dodanie oddzielnych wykresów dla każdej grupy.

Przykład – *ggdensity()*

```
1 ggdensity(dane, x = "hsCRP",
2   color = "grupa",
3   fill = "grupa",
4   palette = c("#99cc00", "#660099", "#0047b3"),
5   ylab = "gestosc",
6   xlab = "hsCRP [mg/l]"
7 )
```

Przykład – *ggdensity()* + *facet_wrap()*

```
1 ggdensity(dane, x = "hsCRP",
2   color = "grupa",
3   fill = "grupa",
4   palette = c("#99cc00", "#660099", "#0047b3"),
5   ylab = "gestosc",
6   xlab = "hsCRP [mg/l]"
7 ) + facet_wrap(~ grupa, scales = "free")
```

W przypadku zastosowania testów wymagających zgodności z rozkładem normalnym dla danych niezgodnych z rozkładem normalnym trzeba liczyć się z otrzymaniem nieprawidłowych wyników, a w konsekwencji nieprawidłowego wnioskowania.

7 Ocena homogeniczności wariancji

W przypadku niektórych testów wymagana jest zarówno zgodność z rozkładem normalnym jak i wymagane jest spełnienie założenia o homogeniczności (jednorodności) wariancji. Najczęściej stosowane testy do oceny jednorodności wariancji: test Fishera, test Levene'a, poniżej przykład użycia testu Levene'a (pakiet *car*).

Przykład – *leveneTest()*

```
1 leveneTest(hsCRP ~ grupa, data = dane)
2 leveneTest(hsCRP ~ grupa, data = dane)$"Pr(>F)"[1] #wydobyć p-value
```

Jeśli wartość p-value > 0.05 oznacza to, że dane są zgodne z założeniem o jednorodności wariancji (możemy założyć homogeniczność danych).

Podobnie jak w przypadku oceny zgodności z rozkładem normalnym, zastosowanie testów wymagających spełnienia założenia o jednorodności wariancji dla danych o niejednorodnych wariancjach prowadzi do otrzymania nieprawidłowych wyników, a w konsekwencji do wyciągnięcia nieprawidłowych wniosków. Okazuje się, że gorsze implikacje ma niespełnienie założenia o homogeniczności wariancji niż niespełnienie założenia o rozkładzie normalnym.

8 Porównywanie grup (porównywanie średnich)

W pierwszej kolejności należy określić charakter porównywanych grup. Czy są to grupy zależne czy niezależne. W przypadku grup zależnych, mówimy o badaniu tych samych parametrów u tej samej grupy, np. badanie pewnych parametrów w pewnych odstępach czasowych. Natomiast w przypadku grup niezależnych mowa o badaniu tych samych parametrów u różnych grup pacjentów np. badanie pewnych parametrów zarówno w grupie kontrolnej, jak i grupach chorych (np. w różnym stadium choroby). W drugim kroku należy określić liczbę porównywanych grup: 2 czy więcej niż 2. Następnie na podstawie oceny charakteru danych (spełnienia lub niespełnienia założenia o zgodności z rozkładem normalnym i o jednorodności wariancji), można określić jakie testy należy zastosować w przypadku porównywania grup. Jako, że testy parametryczne wymagają spełnienia założeń o zgodności z rozkładem normalnym i spełnienia założeń o homogeniczności wariancji, częściej stosowane są testy nieparametryczne. Jednak testy nieparametryczne są słabsze. Testy do porównywania grup pozwalają określić czy pomiędzy badanymi grupami występują istotne statystycznie różnice. W przypadku gdy mamy więcej niż 2 grupy, należy dodatkowo określić pomiędzy którymi grupami te różnice występują, do tego wykorzystuje się testy *post hoc*. W Tabeli 1 przedstawiono schemat wyboru testu statystycznego dla 2 i > 2 grup niezależnych:

Tabela 1: Wyboru testu statystycznego dla 2 i > 2 grup niezależnych.

Porównanie grup niezależnych			
Ilość porównywanych grup	Zgodność z rozkładem normalnym	Jednorodność wariancji	Wybrany test
2	TAK	TAK	test t-Studenta (dla gr. niezależnych)
		NIE	test Welcha
	NIE	-	test Wilcoxona (Manna-Whitneya)
>2	TAK	TAK	test ANOVA (<i>post hoc</i> Tukeya)
		NIE	test Kruskala-Wallisa (<i>post hoc</i> Dunna)
	NIE	-	

8.1 Wybrane przykłady testów statystycznych dla >2 grup niezależnych

Jeśli dane nie spełniają założenia o zgodności z rozkładem normalnym ($p\text{-value} < 0.05$) do analizy porównawczej wykorzystuje się testy nieparametryczne, np. test Kruskala-Wallisa, funkcja `kruskal.test()`. Tak samo w przypadku, gdy dane są zgodne z rozkładem normalnym, ale nie spełniają założenia o jednorodności wariancji to również stosuje się test Kruskala-Wallisa. Zastosowanie wspomnianego testu przedstawiono na poniższym przykładzie:

Przykład – `kruskal.test()`

```
1 kruskal.test(HGB ~ grupa, data = dane)
2 pvalueKWtestHGB <- kruskal.test(HGB ~ grupa, data = dane)$p.value
3
4 if(pvalueKWtestHGB < 0.05){
5   cat(pvalueKWtestHGB, "< 0.05 – sa roznice pomiedzy grupami")
6 }else{
7   cat(pvalueKWtestHGB, "> 0.05 – brak roznice pomiedzy grupami")
8 }
```

Gdy wartość $p\text{-value}$ jest mniejsza niż poziom istotności 0.05 możemy stwierdzić, że istnieją znaczące różnice między grupami. Jeśli występują istotne statystycznie różnice pomiędzy grupami, należy dokładnie określić pomiędzy którymi grupami występują te różnice. Chcąc ocenić pomiędzy jakimi grupami są różnice i jak duże są te różnice należy zastosować testy *post hoc*. Poniżej przedstawiono zastosowanie testu Dunna, umożliwia to funkcja `dunnTest`, wymagane pakiety to `dunn.test` i `FSA`:

Przykład – *dunnTest()*

```
1 dunnTest(dane$HGB, dane$grupa)
```

Należy rozważyć jeszcze inny wariant danych; jeśli dane spełniają założenie o zgodności z rozkładem normalnym ($p\text{-value} > 0.05$) oraz spełniają założenie o jednorodności wariancji ($p\text{-value} > 0.05$) to stosuje się parametryczny test ANOVA, przy użyciu funkcji *aov()*. Zastosowanie parametrycznego testu ANOVA przedstawiono na poniższym przykładzie:

Przykład – *aov()*

```
1 aov(MCHC ~ grupa, data = dane)
2 summary(aov(MCHC ~ grupa, data = dane))
3 pvalueAOVtestMCHC <- summary(aov(MCHC ~ grupa, data = dane))[[1]][["Pr(>F)"]][[1]]
4
5 if(pvalueAOVtestMCHC < 0.05){
6   cat(pvalueAOVtestMCHC, "< 0.05 – sa roznice pomiedzy grupami")
7 }else{
8   cat(pvalueAOVtestMCHC, "> 0.05 – brak roznic pomiedzy grupami")
9 }
```

Podobnie jak w przypadku testu nieparametrycznego, gdy wartość $p\text{-value}$ jest mniejsza niż poziom istotności 0.05 możemy stwierdzić, że istnieją znaczące różnice między grupami. Chcąc określić pomiędzy którymi grupami występują te różnice należy zastosować testy *post hoc*. W przypadku testu ANOVA, często stosowany jest test Tukeya, w R umożliwia to funkcja *TukeyHSD()*:

Przykład – *TukeyHSD()*

```
1 TukeyHSD(aov(MCHC ~ grupa, data = dane))
```

Wspomnieć należy też o zmiennych o innym charakterze. W przypadku zmiennych jakościowych (nominalnych) należy wykonać test χ^2 , w tym celu wykorzystuje się funkcję *chisq.test()*. Przykład zastosowania poniżej + wizualizacja:

Przykład – *chisq.test()*

```
1 chisq.test(dane$grupa, dane$plec)
2 pvalueChisqPlec <- chisq.test(dane$grupa, dane$plec)$p.value
3
4 barplot(table(dane$plec, dane$grupa),
5   ylim = c(0,22),
6   beside = TRUE,
7   col = c("#ffb3b3", "#b3d1ff"),
8   xlab = "grupa",
9   ylab = "plec",
10  legend = c("kobieta", "mezczyzna")
11  )
12 text(1.5, 20, paste("p-value", round(pvalueChisqPlec, digits = 3)))
```

8.2 Wybrane przykłady testów statystycznych dla 2 grup niezależnych

Jeśli dane nie spełniają założenia o zgodności z rozkładem normalnym ($p\text{-value} < 0.05$) do analizy porównawczej do wykonuje się testy nieparametryczne. Można wykonać test Wilcozona (dokładniej test sumy rang Wilcozona zwany również testem Manna–Whitneya). Funkcja umożliwiająca przeprowadzenie wspomnianego testu to `wilcox.test()`. Jeśli wartość $p\text{-value}$ jest mniejsza niż poziom istotności 0.05 możemy stwierdzić, że istnieją znaczące różnice między grupami. Zastosowanie nieparametrycznego testu Manna–Whitneya (Wilcozona) przedstawiono na poniższym przykładzie:

Przykład – `wilcox.test()`

```
1 dwieGrupy <- read.csv2("przykladowe2Grupy.csv", sep = ";")
2 wilcox.test(hsCRP ~ grupa, data = dwieGrupy)
```

Jeśli dane spełniają założenie o zgodności z rozkładem normalnym ($p\text{-value} > 0.05$) oraz spełniają założenie o jednorodności wariancji ($p\text{-value} > 0.05$) to stosuje się test t-Studenta. Test ten można wykonać przy pomocy funkcji `t.test()`, z argumentem o `var.equal = TRUE`. Jeśli wartość $p\text{-value}$ dla testu t-Studenta jest mniejsza niż poziom istotności 0.05 możemy stwierdzić, że istnieją znaczące różnice między grupami. Zastosowanie parametrycznego testu t-Studenta przedstawiono na poniższym przykładzie:

Przykład – `t.test()`, `var.equal = TRUE`

```
1 t.test(LEU ~ grupa, data = dwieGrupy, var.equal = TRUE)
```

Należy rozważyć jeszcze inny wariant; jeśli dane spełniają założenie o zgodności z rozkładem normalnym ($p\text{-value} > 0.05$), ale nie spełniają założenia o jednorodności wariancji ($p\text{-value} < 0.05$) to stosuje się test Welcha. W tym celu można wykorzystać funkcję `t.test()` i dostosować ją do określonej sytuacji poprzez argument `var.equal`. Wartość argumentu powinna przyjąć `FALSE` (`var.equal = FALSE`). Przykład użycia:

Przykład – `t.test()`, `var.equal = FALSE`

```
1 t.test(LEU ~ grupa, data = dwieGrupy, var.equal = FALSE)
```

9 Ocena zależności pomiędzy parametrami

Ocena istnienia i siły korelacji pomiędzy wybranymi parametrami, a także określenie kształtu i kierunku tej zależności stanowią ważną część analizy statystycznej. Niezwykle istotny jest fakt, że stwierdzenie występowania zależności nie zawsze oznacza występowanie związku przyczynowo-skutkowego pomiędzy badanymi parametrami. Oznacza to tylko tyle, że techniczne wykonanie analizy bez wiedzy eksperckiej w określonej tematyce może prowadzić do wykrycia pozornych korelacji, a w konsekwencji niepoprawnej interpretacji wyników. Do przeprowadzenia testu korelacji służy funkcja `cor.test()`, wybór metody określa się w argumente `method`, który przyjmuje argument: `pearson`, `kendall`, `spearman`. Najczęściej stosowaną miarą siły i kierunku zależności jest współczynnik korelacji liniowej Pearsona (parametryczny test korelacji). Nieparametrycznym odpowiednikiem współczynnika korelacji Pearsona jest współczynnik korelacji rangowej Spearmana. Przykłady użycia wspomnianych testów poniżej:

Przykład – `cor.test()` `spearman`

```
1 CHOR1 <- dane %>% filter(grupa == "CHOR1")
2
3 wynikTestuKorelacjiSpearmana <- cor.test(CHOR1$HGB, CHOR1$ERY, method = "spearman")
4 wynikTestuKorelacjiSpearmana$estimate
5 wynikTestuKorelacjiSpearmana$p.value
```

Przykład – `cor.test()` *pearson*

```
1 KONTROLA <- dane %>% filter(grupa == "KONTROLA")
2
3 wynikTestuKorelacjiPearsona <- cor.test(KONTROLA$HGB, KONTROLA$ERY, method = "pearson")
4 wynikTestuKorelacjiPearsona$estimate
5 wynikTestuKorelacjiPearsona$p.value
```

Na podstawie wykonanych testów korelacji można określić czy zależność pomiędzy badanymi parametrami jest istotna statystycznie. W przypadku testu korelacji Pearsona i Spearmana jeśli wartość p-value jest mniejsza od 0.05 to wskazuje to korelację pomiędzy zmiennymi. Współczynnik korelacji r może być interpretowany następująco:

- $r > 0$ korelacja dodatnia – gdy zmienna X rośnie to Y także rośnie,
- $r = 0$ brak korelacji – gdy zmienna X rośnie to Y czasem rośnie a czasem maleje,
- $r < 0$ korelacja ujemna – gdy zmienna X rośnie to Y maleje.

Natomiast siła korelacji może być interpretowana zgodnie z poniższymi przedziałami:

- $-1 < r \leq -0.7$ bardzo silna korelacja ujemna
- $-0.7 < r \leq -0.5$ silna korelacja ujemna
- $-0.5 < r \leq -0.3$ korelacja ujemna o średnim natężeniu
- $-0.3 < r \leq -0.2$ słaba korelacja ujemna
- $-0.2 < r < 0.2$ brak korelacji
- $0.2 \leq r < 0.3$ słaba korelacja dodatnia
- $0.3 \leq r < 0.5$ korelacja dodatnia o średnim natężeniu
- $0.5 \leq r < 0.7$ silna korelacja dodatnia
- $0.7 \leq r < 1$ bardzo silna korelacja dodatnia

Graficzne przedstawienie korelacji pomiędzy parametrami; na potrzeby utworzenia wykresów korelacji można wykorzystać funkcję `ggscatter()` z pakietu `dplyr`. Należy zwrócić uwagę, żeby przy tworzeniu wykresu określić stosowaną metodę, jeśli chcemy uzyskać poprawne dane co do wartości współczynnika i wartości p-value (służy do tego argument `cor.method`), poniżej przykład dla wsp. korelacji Pearsona, z dodatkowym argumentem o dodaniu regresji liniowej.

Przykład – `cor.test()` *pearson*

```
1 ggscatter(KONTROLA, x = "HGB", y = "ERY",
2           add = "reg.line", conf.int = TRUE,
3           cor.coef = TRUE, cor.method = "pearson",
4           color = "grupa", fill = "grupa",
5           ylab = "HGB [g/l]",
6           xlab = "ERY [t/l]"
7           )
```

10 Zadania dodatkowe (dla chętnych)

Zadania prześlij w formie skryptu .R na maila Bogumila.Szubert@cs.put.poznan.pl. Proszę nadać tytuł maila zgodnie z opisem: [SAD_Imię_Nazwisko_zad_dodatkowe](#).

Zad. 1

Wykorzystaj dane: zadanieDodatkowe.csv i uzupełnij braki danych wartością średnią. Zwróć uwagę, że należy się dostosować do poszczególnych grup. Wyjaśniając, jeśli brakuje wartości dla parametru HGB (kolumna HGB) w grupie KONTROLA, to należy wyznaczyć średnią tylko dla tej grupy, a nie dla całej kolumny HGB, która obejmuje także pozostałe grupy.

Zad. 2

Sprawdź czy R umożliwia załadowanie danych w formacie .xls oraz czy jest możliwe aby z jednego pliku zawierającego więcej niż 1 arkusz, wczytać tylko wybrany? Jeśli jest to możliwe to stwórz (lub pobierz gotowy) plik .xls z przynajmniej dwoma arkuszami (zawierającymi różne dane) i wczytaj je do dwóch różnych obiektów. Zaznacz jakie pakiety były do tego wymagane.