

Statystyczna Analiza Danych

Treść projektu

Bioinformatyka II rok

Ogólne założenia projektu

Projekt zaliczeniowy składa się z dwóch składowych: skryptu .R, który ma posłużyć jako narzędzie do przeprowadzenia podstawowej statystycznej analizy danych oraz sprawozdania w formacie .pdf. Sprawozdanie ma opisywać działanie skryptu, w tym zastosowanych metod i przykładowych wyników. Projekt zaliczeniowy należy dostarczyć w formie elektronicznej na maila (Bogumila.Szubert@cs.put.poznan.pl).

Treść projektu

Przygotuj narzędzie (skrypt w języku R) służące do przeprowadzenia podstawowej analizy statystycznej dla danych medycznych, gdzie badane grupy są niezależne (rozważ sytuację w której bada się więcej niż 2 grupy). W celu testowania wykorzystaj plik: przykladoweDane-Projekt.csv.

Skrypt powinien zawierać następujące elementy analizy statystycznej:

1. Przygotowanie danych wejściowych przez porządzenie sobie z brakami danych. Zaraportowanie wszystkich wprowadzonych zmian. Dodatkowo zaraportowanie informacji o wartościach odstających dla wybranych parametrów.
2. Wykonanie charakterystyk dla badanych grup, zapisanie wyników w czytelnej formie (polecana struktura tabelaryczna).
3. Wykonanie analizy porównawczej pomiędzy grupami, określenie czy istnieją istotne statystycznie różnice. Jeśli istnieją istotne statystyczne różnice pomiędzy grupami to zaraportowanie pomiędzy którymi grupami występują i jak istotne są to różnice.
4. Wykonanie analizy korelacji. Zaraportowanie pomiędzy którymi parametrami w obrębie jakich grup występują istotne statystycznie korelacje oraz określenie siły i kierunku korelacji.

Na każdym etapie powyższej analizy pamiętaj, że bardzo ważny jest charakter analizowanych danych, który określa jakie testy należy zastosować. Poza wynikiem testów niemniej ważna jest wizualizacja danych. Staraj się aby na każdym etapie analizy przedstawić wyniki w formie graficznej. Sprawozdanie powinno być napisane jak manual do zaproponowanego narzędzia: opisz jakie są stosowane testy, jak interpretować przykładowe wyniki, jak interpretować generowane wykresy. Dodatkowo punktowane automatyczne utworzenie raportu podsumowującego, jako wynik działania skryptu. Jednak raport nie będzie traktowany jak sprawozdanie i jest oddzielnym dodatkowo punktowanym (niewymaganim do zaliczenia) elementem. Dodatkowo punktowane przygotowanie narzędzia tak aby można je było uruchomić w trybie wsadowym z argumentem wejściowym, którym będzie plik danych w formacie csv.