

Statystyczna analiza danych - projekt zaliczeniowy

Adam Pańczak 163837 Bioinformatyka

1. INICJALIZACJA, PAKIETY I DANE

Etap odpowiada za przygotowanie danych.

Automatyczne zarządzanie bibliotekami: Program posiada system weryfikacji pakietów. Przeszukuje on system w poszukiwaniu wymaganych bibliotek (Hmisc, dplyr, ggpubr, car, FSA, corrplot). Program pobiera i instaluje tylko brakujące pakiety.

```
# 0. INICJALIZACJA, PAKIETY I DANE
pakiety <- c("Hmisc", "dplyr", "ggpubr", "car", "FSA", "corrplot")
for (p in pakiety) {
  if (!require(p, character.only = TRUE)) install.packages(p, dependencies = TRUE)
  library(p, character.only = TRUE)
}
```

Uniwersalne uruchamianie (Tryb wsadowy): Program wspiera uruchamianie w trybie wsadowym. W przypadku standardowego uruchomienia w RStudio, automatycznie wczytany zostanie domyślny plik "przykładoweDane-Projekt.csv".

Wczytywanie danych: Funkcja read.csv2 dba o poprawną konwersję zapisu (kolumny rozdziela średnik i ułamki przecinek).

```
args <- commandArgs(trailingOnly = TRUE)
plik_danych <- if (length(args) > 0) args[1] else "przykładoweDane-Projekt.csv"
dane <- read.csv2(plik_danych, sep = ";", dec = ",", as.is = TRUE)
```

Inicjalizacja raportu: Otwierany jest wirtualny plik Raport_SAD_Wizualizacje.pdf. Wszystkie wykresy wygenerowane przez program zostaną automatycznie zapisane w tym dokumencie. Na koniec system filtruje i zapamiętuje wyłącznie te kolumny, które zawierają liczby, co eliminuje ryzyko błędów w dalszych obliczeniach.

```
pdf("Raport_SAD_Wizualizacje.pdf", width = 8, height = 6)
zmienne_numeryczne <- names(dane)[sapply(dane, is.numeric)]
```

2. PRZYGOTOWANIE DANYCH (Braki i Wartości Odstające)

Opis działania:

Część ta odpowiada za czyszczenie danych przed analizą.

Imputacja braków: Program wykrywa puste komórki i za pomocą funkcji impute uzupełnia je średnią arytmetyczną obliczoną wyłącznie dla konkretnej grupy, do której należy pacjent.

```
for (kol in zmienne_numeryczne) {
  # Imputacja braków średnią w grupach
  if (any(is.na(dane[[kol]]))) {
    for (g in unique(dane$grupa)) {
      idx <- dane$grupa == g
      if (any(is.na(dane[idx, kol]))) dane[idx, kol] <- as.numeric(impute(dane[idx, kol], mean))
    }
    cat("-> Uzupełniono braki danych w parametrze:", kol, "\n")
  }
}
```

Detekcja wartości odstających (IQR): Program poszukuje wartości odstających, czyli wyników skrajnie niskich lub wysokich. Wykorzystuje do tego matematyczną regułę rozstępu międzykwartylowego (różnica między górnym, a dolnym kwartylem). Wyznacza granice:

- Dolna granica: $Q1 - 1.5 * IQR$
- Górna granica: $Q3 + 1.5 * IQR$
- Każdy wynik poza tą strefą jest zliczany, a informacja o liczbie znalezionych wyników jest wyświetlana w konsoli.

```
Q <- quantile(dane[[kol]], c(0.25, 0.75), na.rm = TRUE)
odstajace <- dane[[kol]] < (Q[1] - 1.5 * IQR(dane[[kol]])) | dane[[kol]] > (Q[2] + 1.5 * IQR(dane[[kol]]))
if (any(odstajace)) cat("-> kolumna", kol, "- liczba wartości odstających:", sum(odstajace), "\n")
```

3. STATYSTYKI OPISOWE

Opis działania:

Etap dla każdego parametru tworzy czytelną prezentację danych z podziałem na grupy.

Wyświetla:

- N: Liczba pacjentów w grupie.
- Średnia i SD (Odchylenie standardowe): Informują o przeciętnym wyniku i stopniu jego rozrzutu.
- Mediana: Wartość środkowa, kluczowa przy parametrach niesymetrycznych.
- Min i Max: Zakres uzyskanych wyników.

Wszystkie wskaźniki są automatycznie zaokrąglane do dwóch miejsc po przecinku i wyświetlane w konsoli w formie tabeli

```
for (parametr in zmienne_numeryczne) {
  cat("\nPodsumowanie dla parametru:", parametr, "\n")
  dane %>% group_by(grupa) %>%
    summarise(N = n(), Srednia = round(mean(get(parametr)), 2), SD = round(sd(get(parametr)), 2),
              Mediana = round(median(get(parametr)), 2), Min = min(get(parametr)), Max = max(get(parametr)))
  print()
}
```

Przykładowy output:

Podsumowanie dla parametru: HGB


A tibble: 3 × 7

	grupa	N	Srednia	SD	Mediana	Min	Max
	<chr>	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	CHOR1	25	12.4	1.19	12.4	9.50	14.5
2	CHOR2	25	12.8	2.37	12.6	9.83	22.2
3	KONTROLA	25	11.3	1.06	11.4	9.50	13.2

4. ANALIZA PORÓWNAWCZA (Wielogrupowa)

Opis działania:

Etap przeprowadza analizę porównawczą dla każdego parametru. Program "wybiera" jakie testy wykonać na podstawie schematu:



Przed wyborem testu program bada naturę danych. Testem Shapiro-Wilka sprawdza normalność rozkładu w każdej grupie osobno, a testem Levene'a bada jednorodność wariancji (czy grupy mają podobne rozproszenie wyników).

```
# Sprawdzenie założeń (Shapiro-Wilk i Levene)
p_shapiro <- tapply(dane[[zmienna]], dane$grupa, function(x) if(length(na.omit(x)) >= 3) shapiro.test(x)$p.value else 0)
homogeniczne <- isTRUE(leveneTest(formula_test, data = dane)$`Pr(>F)`[1] > 0.05)
```

Wybór ścieżki testowej:

Ścieżka ANOVA: Jeśli parametry w każdej grupie mają rozkład normalny i ich wariancje są równe, uruchamiany jest test ANOVA (aov). Jeżeli wykaże on istotne różnienia ($p < 0.05$), program automatycznie wykonuje test *post hoc* Tukeya.

```
if (all(p_shapiro > 0.05) && homogeniczne) {
  cat("Założenia spełnione -> Test parametryczny: ANOVA\n")
  wynik_aov <- aov(formula_test, data = dane)
  print(summary(wynik_aov))
  if (summary(wynik_aov)[[1]][["Pr(>F)"]][1] < 0.05) {
    cat("\nTest post hoc Tukeya:\n"); print(TukeyHSD(wynik_aov))
  }
} else {
```


Ścieżka Kruskala-Wallisa: Jeśli choć jedno z założeń zostanie złamane, program przełącza się na test Kruskala-Wallisa. W przypadku wykrycia istotności ($p < 0.05$), uruchamiany jest nieparametryczny test *post hoc* Dunna.

```
} else {
  cat("Założenia niespełnione -> Test nieparametryczny: Kruskala-Wallisa\n")
  wynik_kw <- kruskal.test(formula_test, data = dane)
  print(wynik_kw)
  if (wynik_kw$p.value < 0.05) {
    cat("\nTest post hoc Dunna (Bonferroni):\n"); print(dunnTest(formula_test, data = dane, method = "bonferroni")$res)
  }
}
```

Wizualizacja: Dla każdego parametru do pliku PDF trafiają dwa wykresy: wykres gęstości rozkładu oraz wykres pudełkowy z nałożonymi oryginalnymi punktami pacjentów.


```
#wizualizacja
print(ggdensity(dane, x = zmienna, color = "grupa", fill = "grupa", palette = "jco", ylab = "gęstość", title = paste("Analiza porównawcza: ", zmienna)))
print(ggboxplot(dane, x = "grupa", y = zmienna, color = "grupa", palette = "jco", add = "jitter", title=paste("Analiza porównawcza: ", zmienna)))
```

Analiza porównawcza: LEU



Przykładowe wykresy:

Analiza porównawcza: LEU



5. ANALIZA KORELACJI

Opis działania:

Ostatni etap szuka zależności pomiędzy wszystkimi cechami pacjentów.

Program samodzielnie generuje wszystkie możliwe, unikalne kombinacje par parametrów.

Dla każdej pary wywoływana jest funkcja analiza_korelacji.

```
for (i in 1:(length(kolumny_numeryczne) - 1)) {  
  for (j in (i + 1):length(kolumny_numeryczne)) {  
    analiza_korelacji(dane, gr, kolumny_numeryczne[i], kolumny_numeryczne[j])  
  }  
}
```

Jeśli obie badane cechy mają rozkład normalny, stosowany jest współczynnik Pearsona. W przeciwnym wypadku program używa odpornego współczynnika rang Spearmana.

```
analiza_korelacji <- function(dane, gr, par1, par2) {  
  dane_g <- filter(dane, grupa == gr)  
  metoda <- if(shapiro.test(dane_g[[par1]])$p.value > 0.05 && shapiro.test(dane_g[[par2]])$p.value > 0.05) "pearson" else "spearman"
```

Program filtruje wyniki i generuje wykresy ggscatter wraz z linią trendu i szarym obszarem ufności tylko dla korelacji, gdzie $p < 0.05$.

```
test <- cor.test(dane_g[[par1]], dane_g[[par2]], method = metoda)  
if (test$p.value < 0.05) {  
  r <- test$estimate  
  cat(sprintf("Grupa %s | %s vs %s -> Istotna korelacja %s (r = %.2f, p = %.3f)\n",  
    gr, par1, par2, metoda, r, test$p.value))  
  
  print(ggscatter(dane_g, x = par1, y = par2, add = "reg.line", conf.int = TRUE,  
    cor.coef = TRUE, cor.method = metoda, title = paste("Korelacja", gr, ":", par1, "vs", par2)))  
}
```

Zbiorcza Macierz Korelacji (Corrplot): Na sam koniec pętli dla każdej grupy generowany jest całościowy profil relacji w postaci graficznej mapy korelacji (corrplot). Rysowana jest wyłącznie dolna część macierzy (type = "lower"). Siła korelacji zakodowana jest rozmiarem i kolorem kółek (od ciemnoczerwonego dla korelacji dodatnich, do ciemnoniebieskiego dla ujemnych).

```
cat("-> Generowanie zbiorczej macierzy korelacji dla grupy:", gr, "\n")
dane_g_num <- filter(dane, grupa == gr) %>% select(all_of(kolumny_numeryczne))

#Tworzenie macierzy
macierz_kor <- cor(dane_g_num, method = "spearman", use = "complete.obs")

corrplot(macierz_kor, method = "circle", type = "lower",
          tl.col = "black", tl.srt = 45,
          main = paste("\nMacierz korelacji Spearmana - Grupa:", gr))
```

Program kończy pracę poleceniem dev.off(), które ostatecznie zamyka i zapisuje gotowy plik PDF na dysku komputera.

```
dev.off()
cat("Koniec analizy. Raport z wykresami zapisano w pliku 'Raport_SAD_Wizualizacje.pdf'.\n")
```

===Wyświetlanie wyników===

1. Ilość wartości odstające w etapie przygotowania danych jest wyświetlana w konsoli dla każdej kolumny:

```
-> Kolumna wiek - liczba wartości odstających: 1
-> Kolumna hsCRP - liczba wartości odstających: 4
-> Kolumna ERY - liczba wartości odstających: 1
-> Kolumna PLT - liczba wartości odstających: 2
-> Uzupełniono braki danych w parametrze: HGB
-> Kolumna HGB - liczba wartości odstających: 1
-> Kolumna HCT - liczba wartości odstających: 1
-> Kolumna MCHC - liczba wartości odstających: 4
-> Uzupełniono braki danych w parametrze: MON
-> Kolumna MON - liczba wartości odstających: 5
>
```

program wyświetla również w których kolumnach wypełnił braki. Wartości odstające, można zobaczyć na grafie generowanym w późniejszym kroku.

2. W etapie statystyk opisowych program wyświetla tabelę dla każdego parametru z podziałem na grupy w konsoli:

Podsumowanie dla parametru: hsCRP

A tibble: 3 × 7

	grupa	N	Srednia	SD	Mediana	Min	Max
	<chr>	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	CHOR1	25	6.1	8.82	3.97	0.488	42.6
2	CHOR2	25	5.54	4.65	3.45	0.335	19.2
3	KONTROLA	25	5.3	4	4.22	0.758	14.4

grupa oraz N (Liczność próby):

Pokazuje, że w każdej z trzech grup (CHOR1, CHOR2, KONTROLA) znajduje się dokładnie po 25 pacjentów.

Srednia (Średnia arytmetyczna):

Suma wszystkich wyników podzielona przez ich liczbę.

Mediana to wartość dokładnie środkowa. W grupie CHOR1 wynosi 3.97, co oznacza, że połowa chorych ma wynik poniżej 3.97, a połowa powyżej.

SD (Odchylenie standardowe):

Mówi o tym, jak bardzo wyniki pacjentów "rozrzucają się" wokół średniej.

Min (Minimum) i Max (Maksimum):

Wyznaczają pełen zakres (rozstęp) uzyskanych wyników.

3. W etapie analizy porównawczej generowane są raporty z wykonywanych testów statystycznych np.:

ANALIZA: ERY

Założenia niespełnione -> Test nieparametryczny: Kruskala-Wallis

Kruskal-Wallis rank sum test

data: ERY by grupa

Kruskal-Wallis chi-squared = 3.737, df = 2, p-value = 0.1544

ANALIZA: HGB

Założenia niespełnione -> Test nieparametryczny: Kruskala-Wallis

Kruskal-Wallis rank sum test

data: HGB by grupa

Kruskal-Wallis chi-squared = 14.345, df = 2, p-value = 0.0007673

Test post hoc Dunna (Bonferroni):

Kruskal-Wallis rank sum test

data: x and g

Kruskal-Wallis chi-squared = 14.3452, df = 2, p-value = 0

Dunn's Pairwise Comparison of x by g
(Bonferroni)

Col Mean- Row Mean	CHOR1	CHOR2
CHOR2	-0.120160 1.0000	
KONTROLA	3.218343 0.0039*	3.338503 0.0025*

$\alpha = 0.05$

Reject H_0 if $p \leq \alpha$, where $p = \Pr(|Z| \geq |z|)$

	Comparison	Z	P.unadj	P.adj
1	CHOR1 - CHOR2	-0.1201601	0.9043562952	1.000000000
2	CHOR1 - KONTROLA	3.2183431	0.0012893348	0.003868004
3	CHOR2 - KONTROLA	3.3385033	0.0008423104	0.002526931

Gdy interesuje nas istotność różnic rozważamy parametr p-value. Jeżeli jest on mniejszy od 0.05 traktuje się różnicę jako istotną, nim p jest bliższe zera tym bardziej istotne. Patrząc na analizę parametru ERY - pierwszy test wykazał, że $p > 0,05$. Program nie przeprowadza więc głębszej analizy. Dla HGB mamy $p < 0.05$. Program uruchamia test post hoc, widzimy, że różnica pomiędzy grupą kontrola, a CHOR1 i CHOR2 jest istotna (niskie p.adj). Różnica pomiędzy CHOR1,a CHOR2 okazała się nieistotna ($p = 1$).

Na tym samym etapie generowane są dwa rodzaje grafów:


1. Wykres gęstości

Wykres gęstości to wygładzona wersja klasycznego histogramu. Służy on do oceny, jak "rozłożone" są wyniki w poszczególnych grupach/

Oś pozioma (X): Przedstawia wartości badanego parametru.

Oś pionowa (Y): Pokazuje gęstość (częstość) występowania danego wyniku.

Analiza porównawcza: MCHC



2. Boxplot


Ten wykres pokazuje, gdzie znajduje się „środek” danych oraz jak bardzo wyniki są rozproszone. Dodatkowo na wykres naniesione są kropki, z których każda reprezentuje jednego, konkretnego pacjenta.

Pudełko: Obejmuje ono środkowe 50% pacjentów w danej grupie.

Pogrubiona pozioma linia wewnątrz pudełka: To mediana. Dzieli ona grupę na dwie równe połowy – połowa pacjentów ma wynik wyższy, a połowa niższy od tej linii.

Pionowe linie (wąsy): Pokazują zakres typowych wyników. Punkty leżące daleko poza wąsami to statystyczne wartości odstające (anomalie).

Analiza porównawcza: PLT



4. Korelacje

W etapie korelacji tworzone są:


1. Wykresy korelacji - Generowane tylko dla tych par parametrów, między którymi testy wykazały istotną zależność.

Punkty: Każda kropka to jeden pacjent. Jej położenie zależy od wyniku pierwszego badania (oś X) i drugiego badania (oś Y).

Prosta linia: To linia trendu. Pokazuje ogólny kierunek zależności.

Szary obszar: To margines błędów statystycznych.

Jeśli linia wznosi się od lewej do prawej, korelacja jest dodatnia (wzrost jednego parametru to wzrost drugiego). Jeśli opada, korelacja jest ujemna (wzrost jednego powoduje spadek drugiego). Im bliżej linii trendu skupione są kropki (i im węższy jest szary obszar), tym zależność jest silniejsza i bardziej przewidywalna. Wynik R informuje o sile w skali od -1 do 1. Wynik p potwierdza, że obserwowany trend nie jest przypadkowy ($p < 0,05$).



2. Macierz korelacji: zbiorcze podsumowanie wszystkich relacji między wszystkimi badanymi parametrami wewnątrz jednej grupy.

Na przecięciu wiersza i kolumny znajduje się symbol graficzny opisujący relację między nimi.

Kolory ciepłe (odcienie czerwieni/pomarańcza) oznaczają korelację ujemną. Kolory zimne (odcienie niebieskiego) oznaczają korelację dodatnią. Im większe i bardziej nasycone kolorem jest kółko, tym korelacja jest silniejsza. Brak symbolu lub małe białe kółko oznaczają brak związku między badanymi parametrami lub związek tak słaby, że jest nieistotny. Macierz jest rysowana tylko w dolnej połowie, aby nie dublować tych samych informacji.

Macierz korelacji Spearmana – Grupa: CHOR1

